

Wyszukiwarka lokalna

Dokumentacja wstępna

Alesia Filinkova 336180

Diana Pelin 335892

Opis tematu

Celem projektu jest wykonanie lokalnej wyszukiwarki plików tekstowych i dokumentów. Program będzie skanował wskazane katalogi, zapisywał informacje o plikach w bazie SQLite oraz indeksował ich treść. Obsługiwane będą pliki .txt, pliki bez rozszerzenia, .tex oraz .pdf, które przed indeksowaniem będą konwertowane do czystego tekstu przy użyciu zewnętrznych narzędzi systemowych. Program ma umożliwiać wyszukiwanie zarówno po nazwie pliku, jak i po treści, a w wynikach ma zwracać również kontekst wystąpienia frazy, czyli fragment tekstu otaczający dopasowanie.

Wstępny sposób realizacji

Aplikacja zostanie napisana w C++ i zbudowana modułowo. Przewidywane główne moduły:

1. **Scanner** - rekurencyjne przechodzenie po katalogach, filtrowanie typów plików, odczyt metadanych systemowych.
2. **Extractor** - pobieranie czystego tekstu z plików:
 - o .txt i pliki bez rozszerzenia: bezpośredni odczyt
 - o .pdf: wywołanie zewnętrznego narzędzia, np. pdftotext
 - o .tex: bezpośredni odczyt pliku źródłowego jako tekstu
3. **Indexer** - tokenizacja tekstu, normalizacja znaków, budowa indeksu odwrotnego oraz zapis informacji o pozycjach dopasowań potrzebnych do generowania kontekstu
4. **Repository / Database** - zapis indeksu i metadanych plików w lokalnej bazie (SQLite)
5. **Refresh engine** - porównywanie aktualnego stanu systemu plików z bazą i wykonywanie operacji: dodanie, aktualizacja, usunięcie.
6. **Search engine** - wyszukiwanie po nazwie pliku i po treści, zwracanie listy trafień wraz z fragmentem kontekstu
7. **CLI** - interfejs tekstowy do komend typu index, refresh, search-content, search-name

Do przechowywania danych zostanie użyta baza SQLite zapisana lokalnie w pliku. Do ekstrakcji tekstu z plików PDF zostanie użyte narzędzie pdftotext. Program będzie porównywał aktualny stan plików z danymi w bazie i aktualizował tylko te rekordy, które uległy zmianie.

Lista funkcjonalności

1. Indeksowanie plików .txt
2. Indeksowanie plików bez rozszerzenia traktowanych jako tekstowe
3. Ekstrakcja i indeksowanie treści plików .pdf
4. Indeksowanie plików .tex
5. Przechowywanie w bazie danych metadanych plików oraz ich treści przetworzonej do postaci indeksu
6. Odświeżanie indeksu bez budowania bazy od początku
7. Wykrywanie plików nowych, zmodyfikowanych i usuniętych
8. Wyszukiwanie po nazwie pliku
9. Wyszukiwanie po zawartości pliku
10. Prezentacja kontekstu wystąpienia wyszukiwanej frazy

11. Obsługa podstawowych błędów: brak dostępu do pliku, błędna konwersja, nieobsługiwany format, uszkodzony plik
12. Interfejs CLI umożliwiający uruchamianie indeksowania, odświeżania i wyszukiwania

Sposób testowania

Program będzie testowany na przygotowanych plikach różnych typów. Testy obejmą indeksowanie, odświeżanie indeksu, wyszukiwanie po nazwie i treści oraz obsługę błędów odczytu i konwersji.

Tabela zadań i oszacowanie czasu

Zadanie	Podzadanie	Czas
Analiza problemu i wybór technologii	wybór formatu indeksu, wybór SQLite i narzędzi zewnętrznych, projekt struktury danych	12
Przygotowanie architektury aplikacji	podział na moduły, interfejsy, przepływ danych między modułami	10
Implementacja skanowania katalogów	rekurencyjne przeszukiwanie, filtrowanie typów plików, odczyt metadanych	14
Implementacja ekstrakcji tekstu	obsługa .txt, plików bez rozszerzenia, integracja z pdftotext, obsługa .tex	18
Projekt i implementacja bazy danych	schemat tabel, zapis metadanych, zapis indeksu, usuwanie danych	16
Implementacja indeksera	tokenizacja, normalizacja, zapis pozycji słów, aktualizacja indeksu	20
Implementacja mechanizmu odświeżania	wykrywanie zmian, aktualizacja tylko zmienionych plików, usuwanie nieaktualnych rekordów	18
Implementacja wyszukiwania	wyszukiwanie po nazwie, wyszukiwanie po treści, ranking i agregacja wyników	16
Generowanie kontekstu wyników	wyznaczanie fragmentu tekstu wokół dopasowania, formatowanie wyniku	10
Implementacja interfejsu CLI	parser argumentów, komendy użytkownika, komunikaty błędów	10
Integracja modułów i poprawki	połączenie całości, poprawa stabilności, optymalizacje	14
Dokumentacja i przygotowanie oddania	instrukcja uruchomienia, opis architektury, uporządkowanie projektu	8
Suma		166

Uwagi końcowe

Zakładamy realizację kompletnej wersji podstawowej obejmującej indeksowanie, odświeżanie, wyszukiwanie po nazwie i treści oraz prezentację kontekstu.